GİRİŞ

Eğitmen

Elif ÖZKAN



linkedin.com/in/eliffozkan/
github.com/eliffozkan

Özgür YILDIRIM



linkedin.com/in/Ozgur-yldrm/
github.com/OzgurYldrm

- Ders 1: Veri ve özet istatistik
- Histogram, scatter, IQR, box/violin
- Eksik veri ve GroupBy
- Ders 2: Scaling ve encoding
- Korelasyon ve temiz tablo kontrolü

Sunum + Notebook + Homework → Github

Dataset

Tabular Data: Row ve column'lardan oluşan iki boyutlu tablo benzeri verilerdir.

Column: Sütun, genelde her bir sütun bir özelliği temsil eder.

Row: Satır, genelde her bir satır bir adet veriyi temsil eder

id	isim	yaş	gelir (10k $)
1	Ashish	25	22.5
2	Noam	40	30.0
3	Niki	50	41.75

Integer: Tam sayı
Float: Ondalıklı sayı
Object: Genel Python nesneleri
Category: Kategorik veri tipi

int32 / float64: bit genişliği.
float64 genellikle daha yüksek hassasiyet ve daha fazla bellek kullanır.

NaN: eksik veya tanımsız sayısal değer.
Boş hücreleri kontrol et; her geçersiz değer otomatik NaN olmaz.

Mean-Median-Min-Max-Mode

Genellikle sayısal ifadeler için hesaplanır.

min →sayısal değeri en küçük olan eleman → min(1,2,3) , min(L)
argmin → Sayısal değeri en küçük olan elemanın bulunduğu index

max →sayısal değeri en büyük olan eleman → max(1,2,3) , max(L)
argmax → Sayısal değeri en büyük olan elemanın bulunduğu index

Mean → Aritmetik ortalama $\frac{\text{Elemanların toplamı}}{\text{Eleman sayısı}}$

Median: sıralı verinin ortası.
1,2,3,4,5 → 3; 1,2,3,4 → 2.5

1,2,3,4,5 → Median = 3

count → Listedeki eleman sayısı
Mode → Bir set içerisinde en fazla tekrar eden değer

Standart Deviation
(Standart Sapma)

Standart sapma yayılımı ölçer. Bu örnekte bölen n.
Pandas .std() varsayılanı n−1; NumPy .std() varsayılanı n.
Z-score: (x−mean)/std; Modified Z-score: median/MAD temelli.

x	$(x\text{-mean})^2$
10	225
20	25
30	25
40	225

mean = 25

std = $(500/4)^{1/2}$ = 11.18

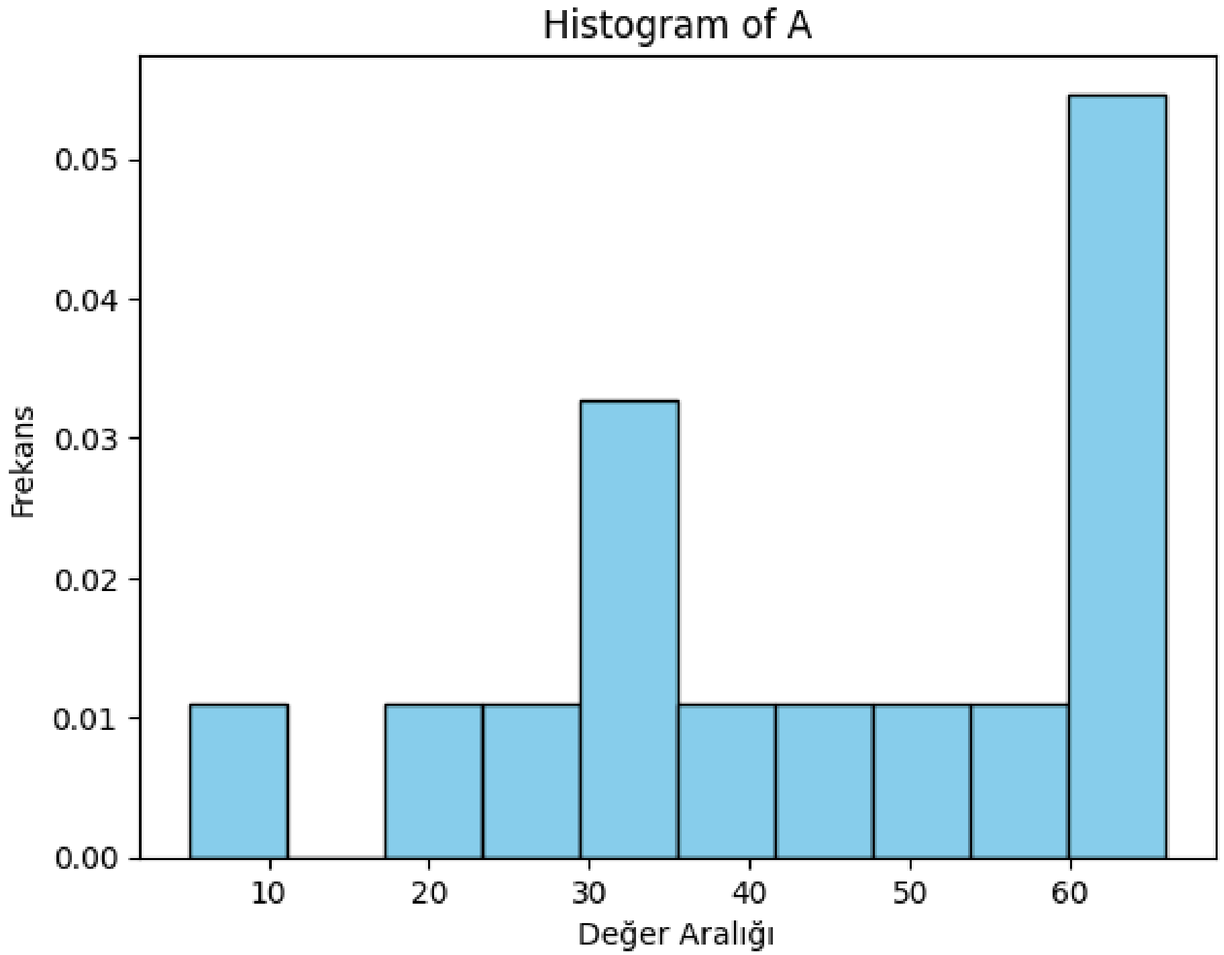
$$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Variance (Varyans) : Standart sapmanın karesi, yayılım ölçüsüdür.

Histogram

continuous verilerin görselleştirilmesini sağlayan bir yöntem

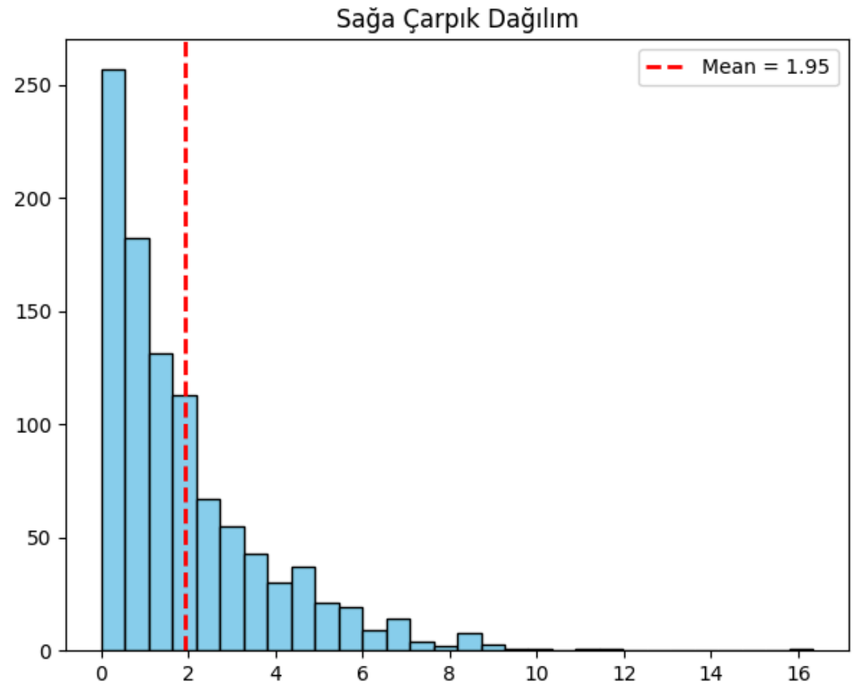
Veriler için belirli aralıklar (bins) belirlenir ve her aralığa kaç tane veri düştüğü sayılır.

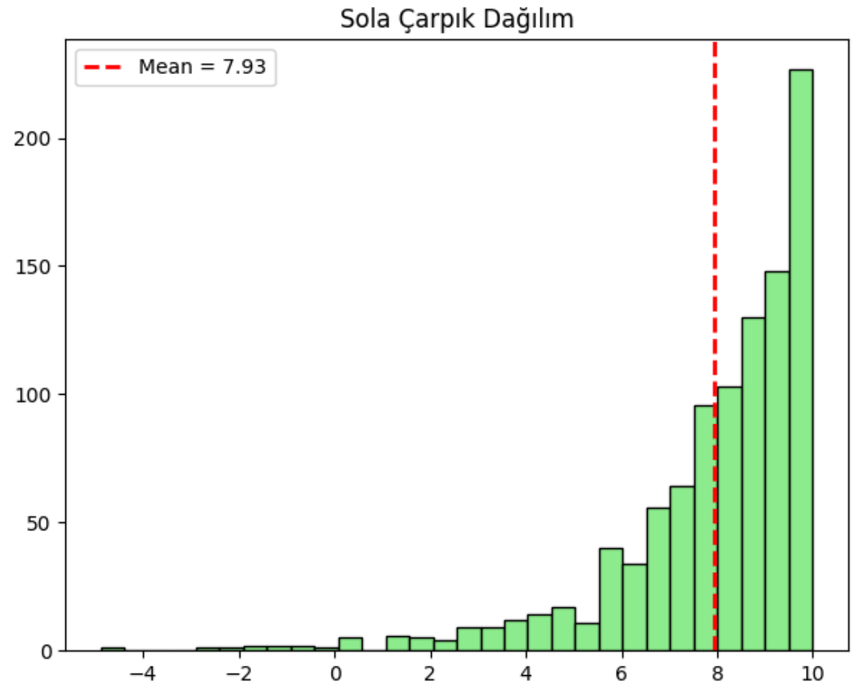


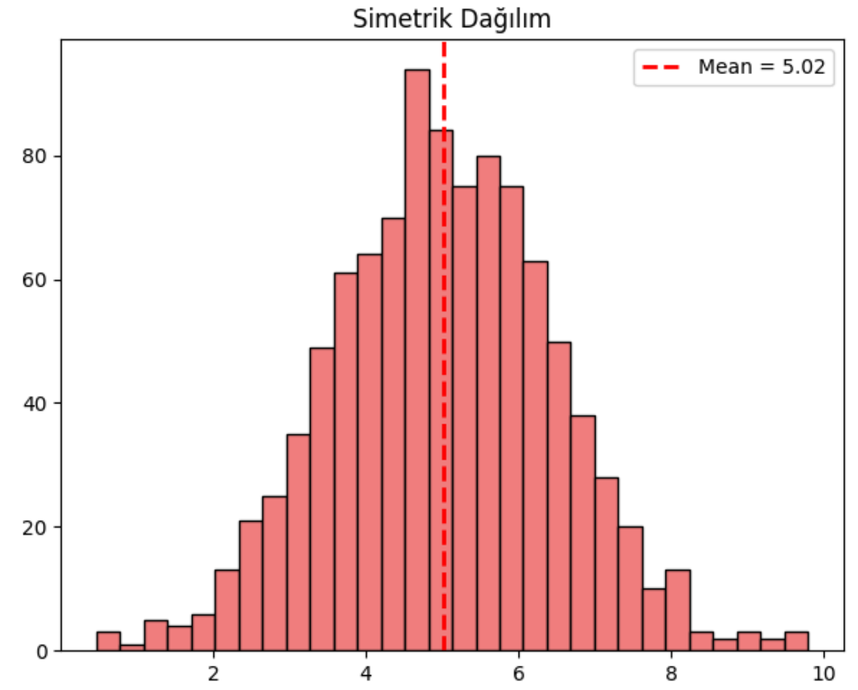
'A': [5,20,25,30,32,35,37,45,50,55,60,62,64,64,66]

- **Verinin simetrik olup olmadığı**
- **Uç değerler**
- **Yoğun bölgeler**

Skewness

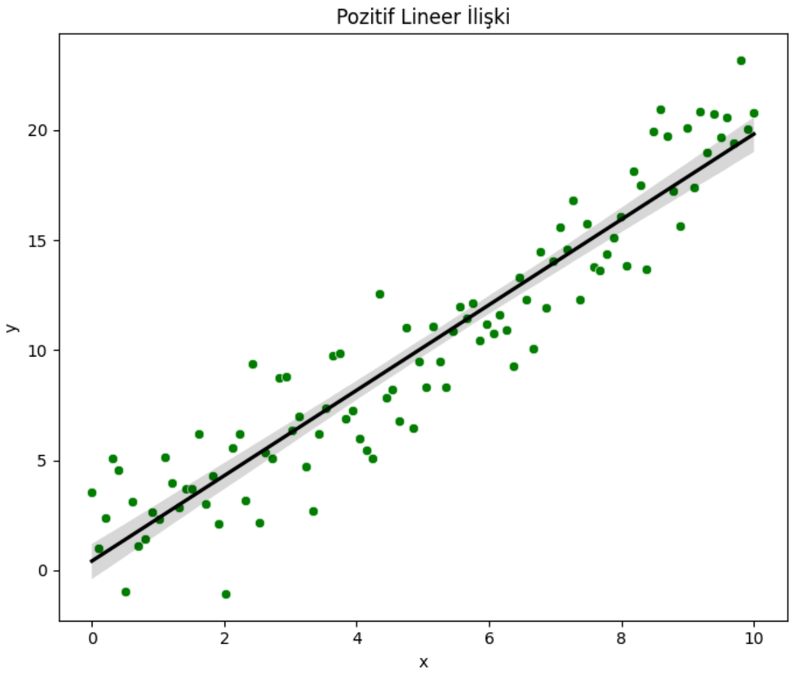

Sağa Çarpık Dağılım
Mean = 1.95
0
50
100
150
200
250
0
2
4
6
8
10
12
14
16

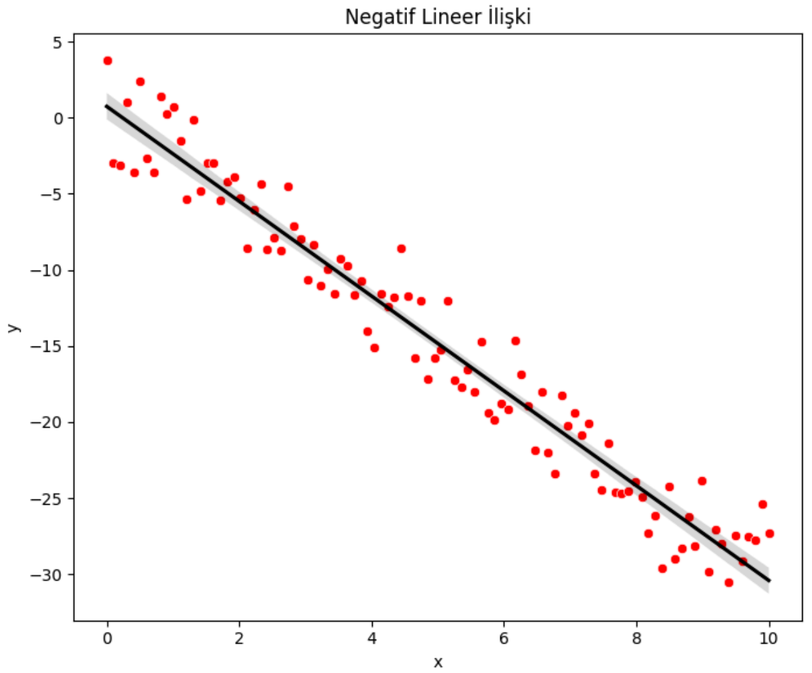

Sola Çarpık Dağılım
Mean = 7.93
0
50
100
150
200
−4
−2
0
2
4
6
8
10

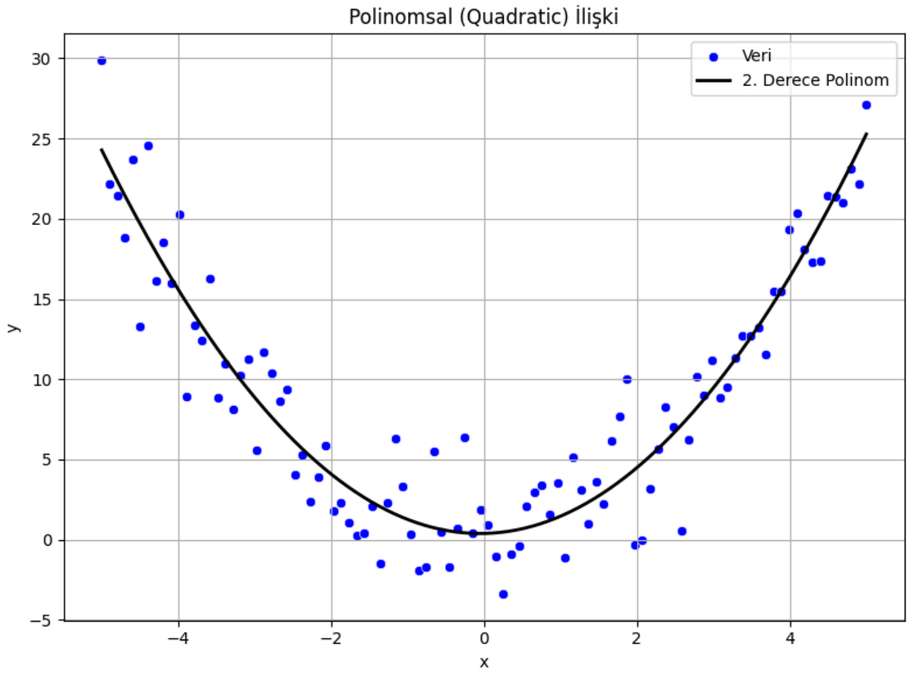

Simetrik Dağılım
Mean = 5.02
0
20
40
60
80
2
4
6
8
10

Scatter Plot - continuous

İki değişken arasındaki ilişkiyi incelemek için kullanılır





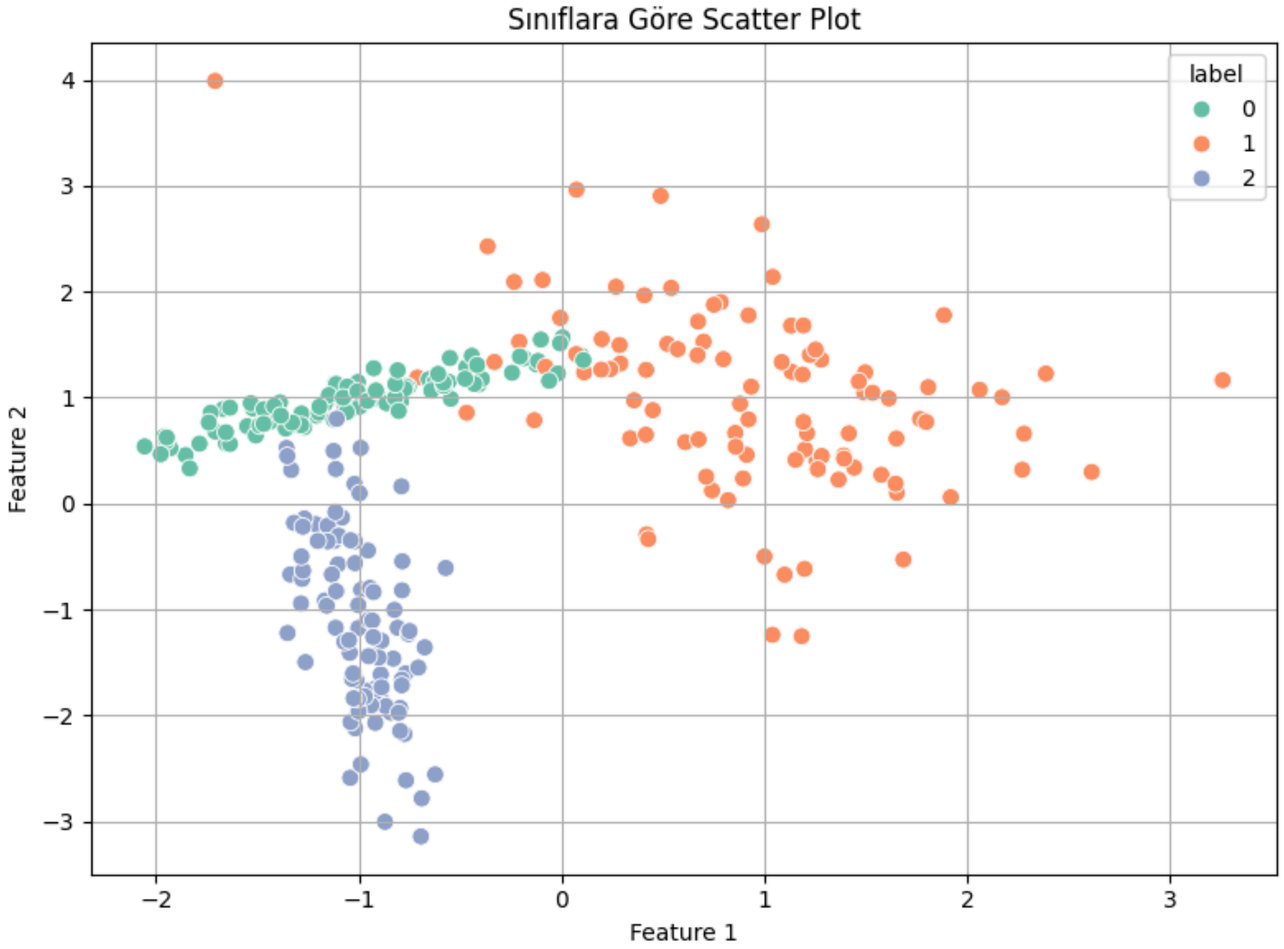


Her bir nokta bir veriyi ifade eder. Verilerin sahip oldukları iki feature kullanılarak bu grafikler çizilir

Bu grafikler kullanılarak

- **Korelasyon ve ilişki**
- **Veri yoğunluğu**
- **Outlier**

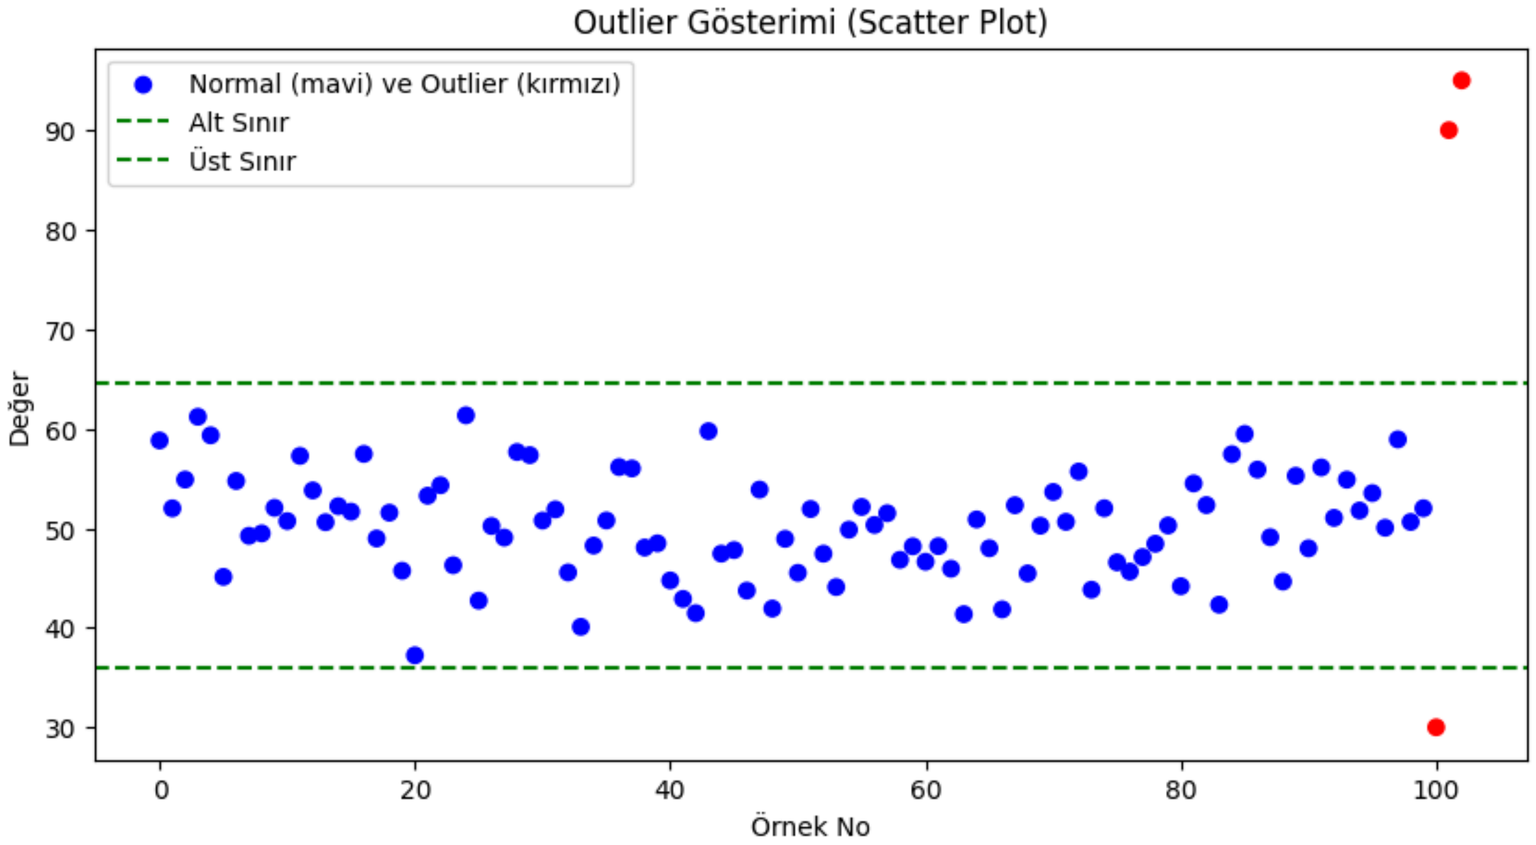
Scatter Plot - Class



Hedef sınıfların kümelenme durumu bu grafikler ile incelenebilir

Outlier

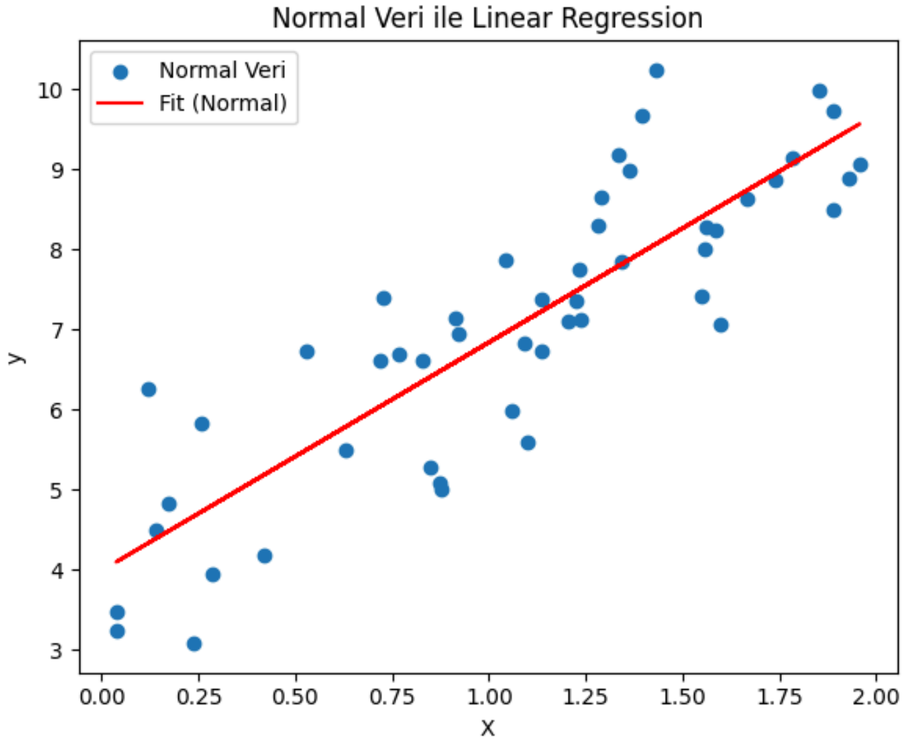
Outlier: diğer gözlemlere göre alışılmadık derecede uzak değer.
Verinin normal dağılımlı olması gerekmez.

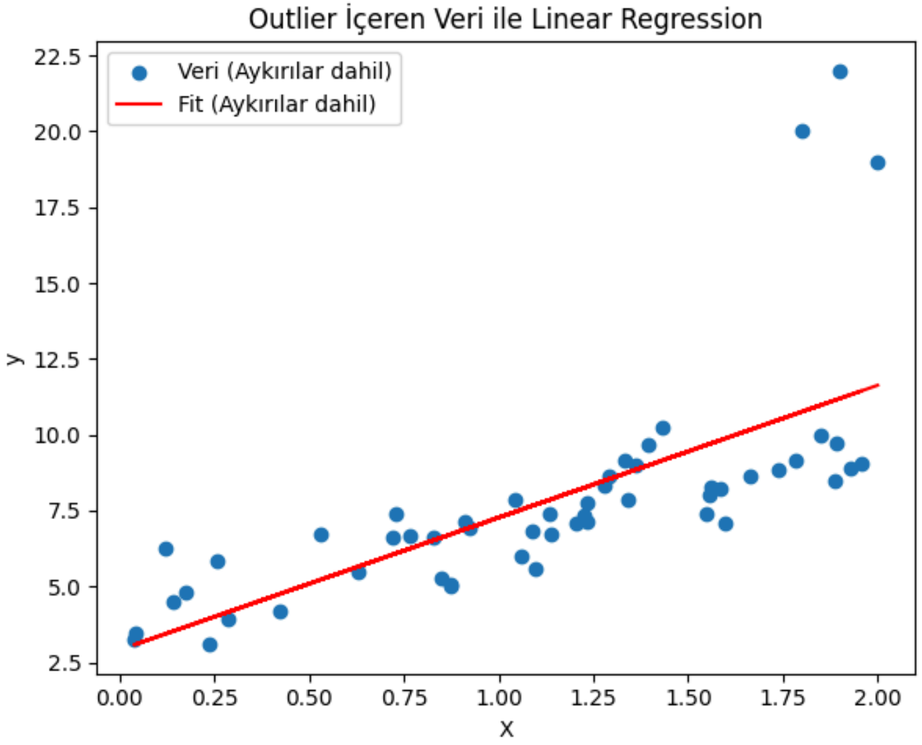


Outlier değerler

- Ölçüm hatalarından
- Veri ön işlemedeki hatalardan
- Bazen de doğal olarak

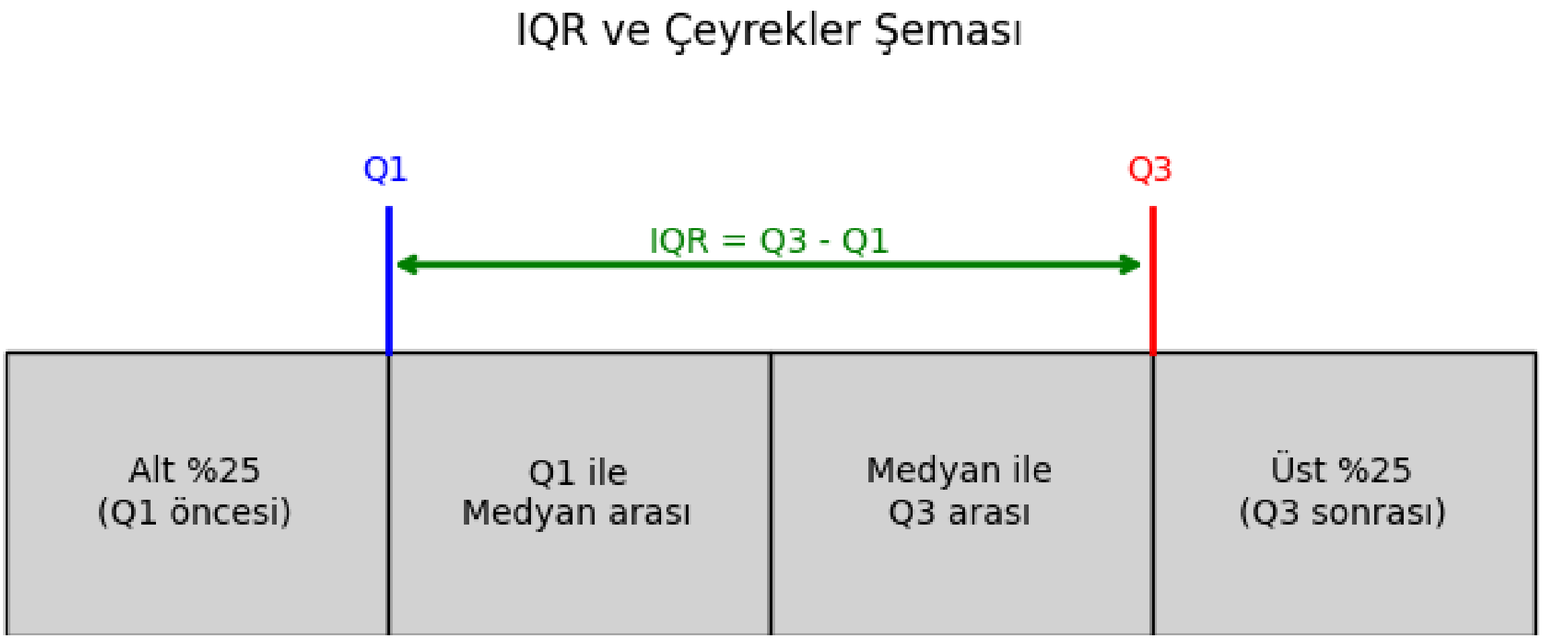
Outlier Etkileri





- Uç değerler bazı modellerin parametrelerini ve hata ölçüsünü güçlü etkileyebilir.
- Önce ölçüm hatası mı, anlamlı bir gözlem mi araştır.
- Her uç değer silinmez; notebookta iki alternatif karşılaştırılır.

Interquartile Range (IQR)



Veri seti küçükten büyüğe sıralanınca
First Quantile (Q1) = %25. nokta
Third Quantile (Q3) = %75. nokta

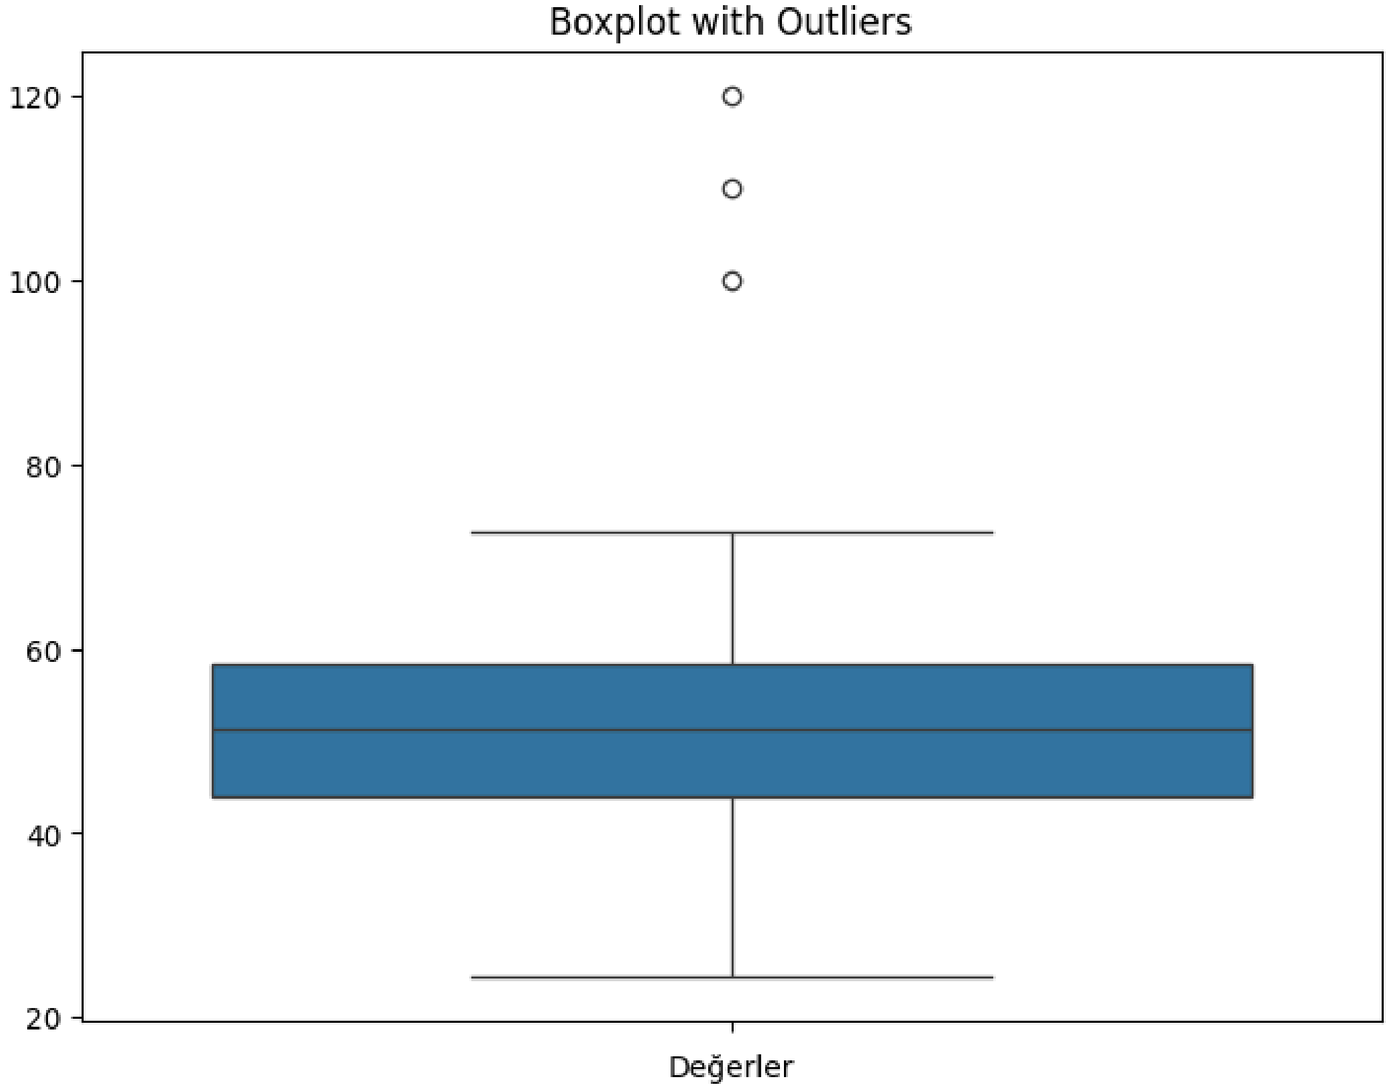
Alt sınır = Q1 - 1.5 * IQR
Üst Sınır= Q3 + 1.5 * IQR

Bu sınırlar dışında kalan değerler outlier olarak kabul edilebilir

Q1 = 50
Q3 = 150 → **IQR = 100** → **Alt Sınır = -100**
Üst Sınır = 300 → **-100'den küçük ve 300'den büyük değerler outlier**

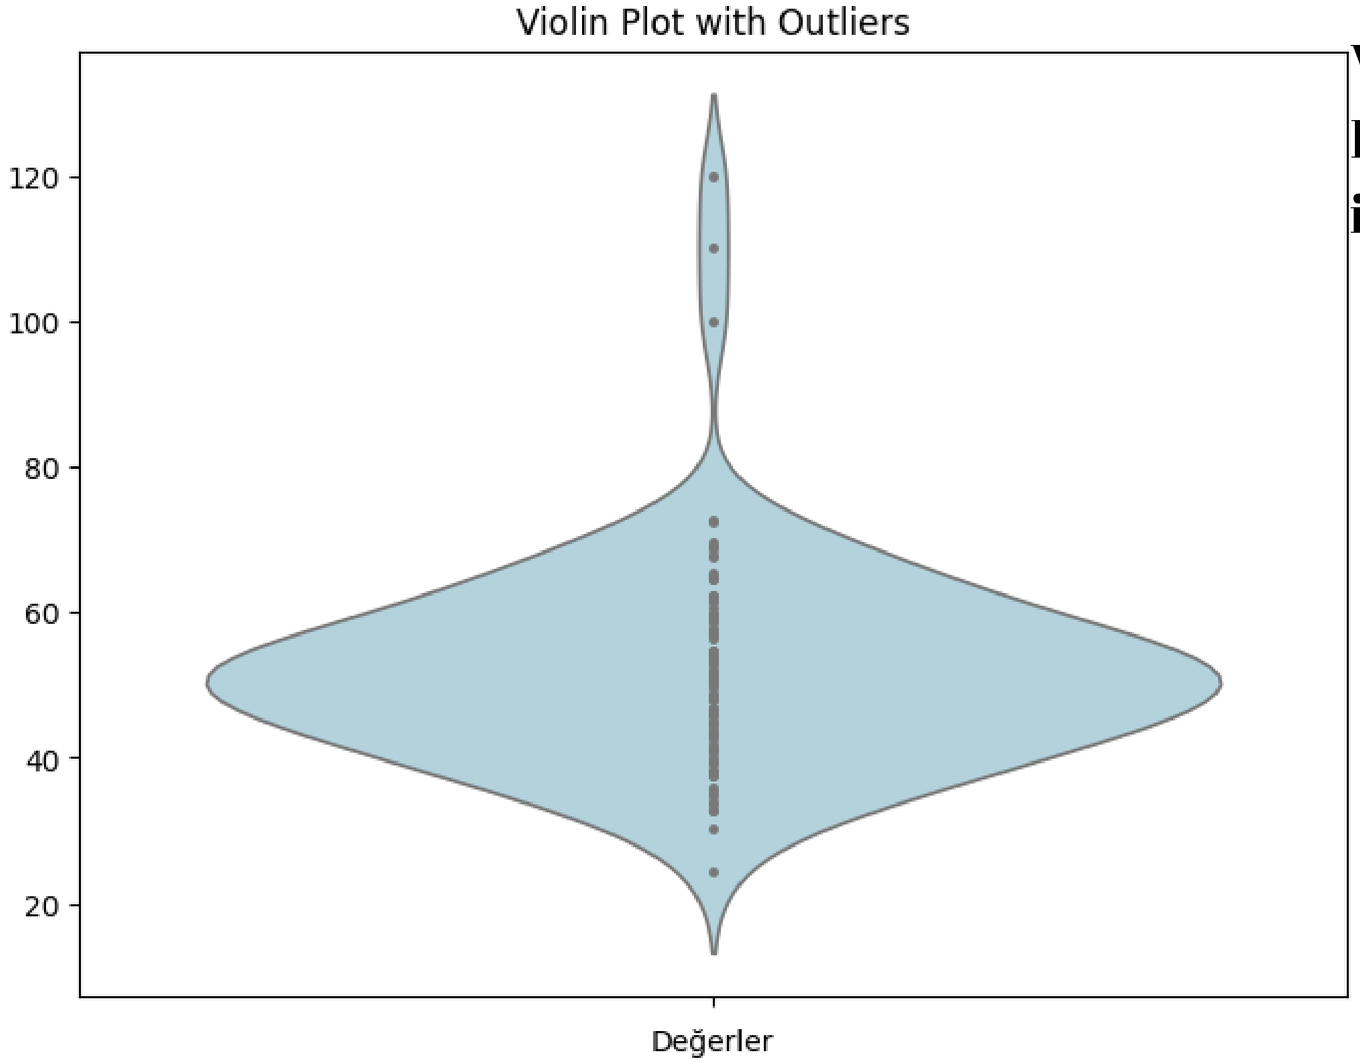
***1.5 yerine 3 gibi daha büyük çarpanlar kullanılması sadece daha aykırı verilerin seçilmesini sağlar**

Box Plot



Outlier görselleştirmek için kullanılır. Whisker dışında kalan noktalar outlier'ları ifade eder

Violin Plot



Violin plot dağılımın yoğunluğunu gösterir. Box plot ile birlikte yayılımı ve uzak gözlemleri incele.

Handling Outliers

Önce kaynağını ve anlamını araştır.

Alternatifler: koru / satırı sil / sınır değerine çek.

Notebookta silme ve sınıra çekme ayrı örneklerdir.

Missing Data

id	isim	yaş	gelir (10k $)
1		25	22.5
2	Noam		
3	Niki	50	41.75

- Sayısal eksik: mean veya median.
- Kategorik eksik: mode veya anlamlı sabit (Unknown).
- Çok eksikli sütunu kaldırmadan önce anlamını kontrol et.
- Öğrenilen doldurma değerleri yalnızca train'den hesaplanır.

Group By

Meslek	Maaş
Mühendis	
Doktor	10000
Mühendis	11000
Öğretmen	12000
Doktor	
Öğretmen	
Mühendis	13000

Group By Meslek

Mühendis	
Mühendis	11000
Mühendis	13000

Boş maaş = 12000

Doktor	10000
Doktor	

Boş maaş = 10000

Öğretmen	12000
Öğretmen	

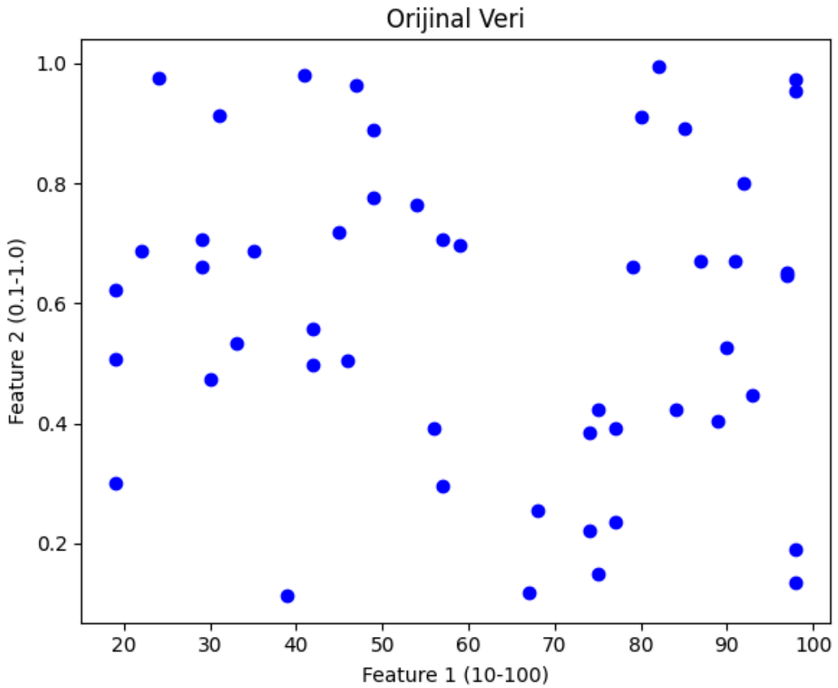
Boş maaş = 12000

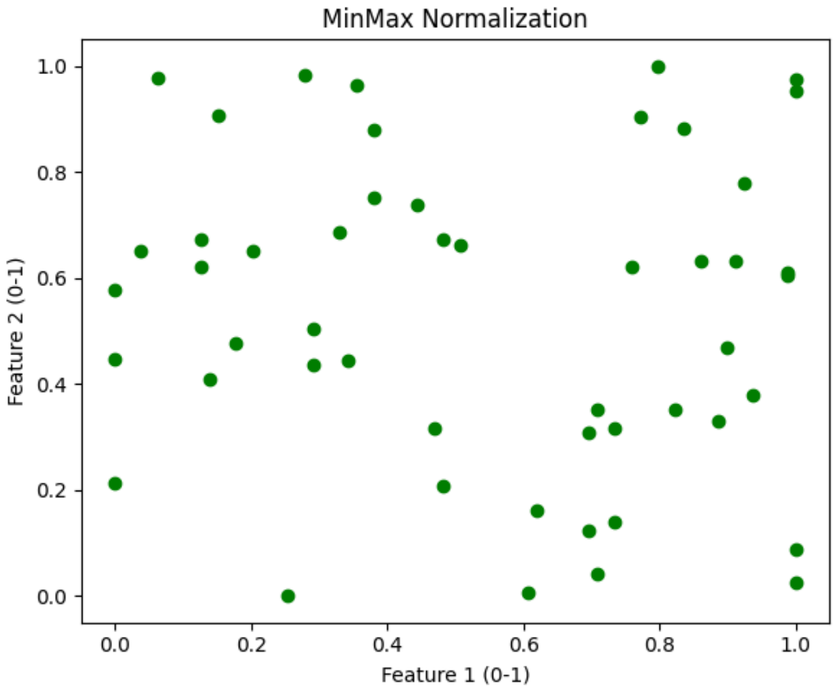
Belirli bir(kaç) sütuna göre gruplama yapıldıktan sonra her boş veri ait olduğu grubun

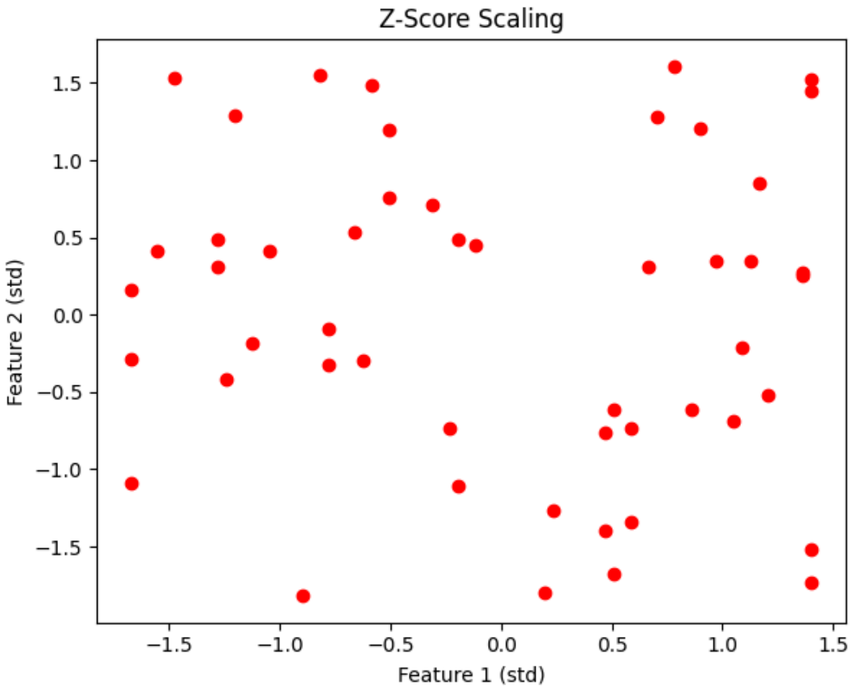
- mean
- mode
- median

değerleri ile doldurulabilir

Feature Scale







!!Eksen değer aralıkları farklı

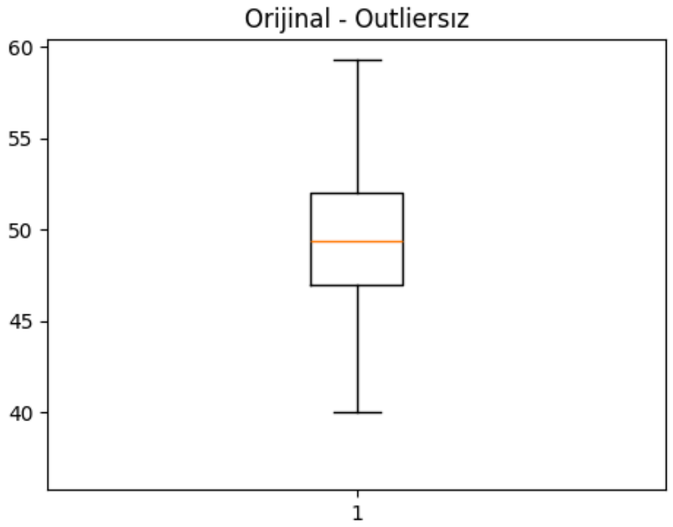
- Farklı ölçekler, mesafe hesabını ve gradient descent'i etkileyebilir.
- MinMax ve StandardScaler ölçekleri karşılaştırılabilir yapar.
- Scaler train'de fit; validation/test'te transform edilir.

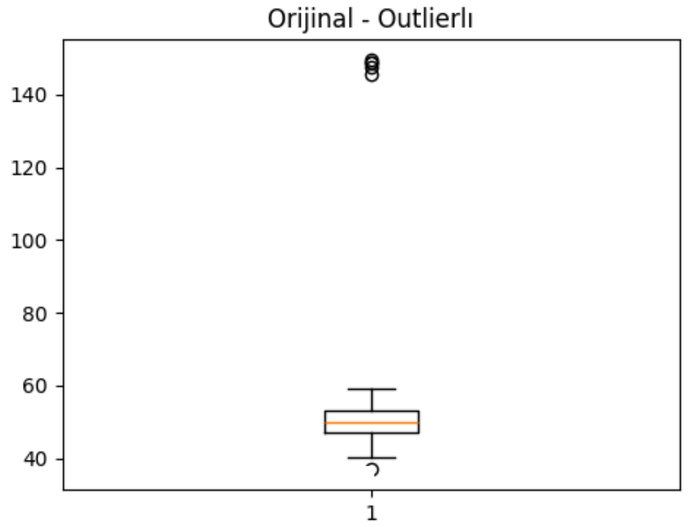
Feature Scale

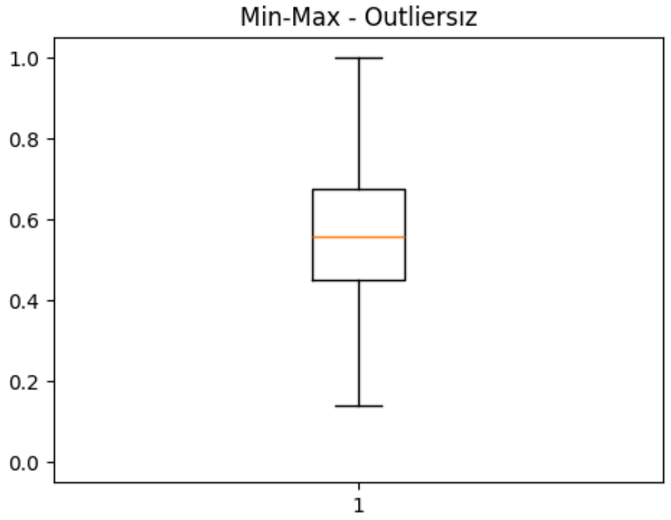
Normalization	Standardization
Sabit bir aralığa koyar (0-1 gibi)	Mean değerini 0 std değerini 1 yapmayı amaçlar. Aralığı sabit değildir.
Outlier'lar etkiler (genellikle)	Mean/std, outlier'lardan etkilenir
Ölçekleri farklı ve min-max önemli olan verilerde kullanılır	Normal dağılım şart değildir

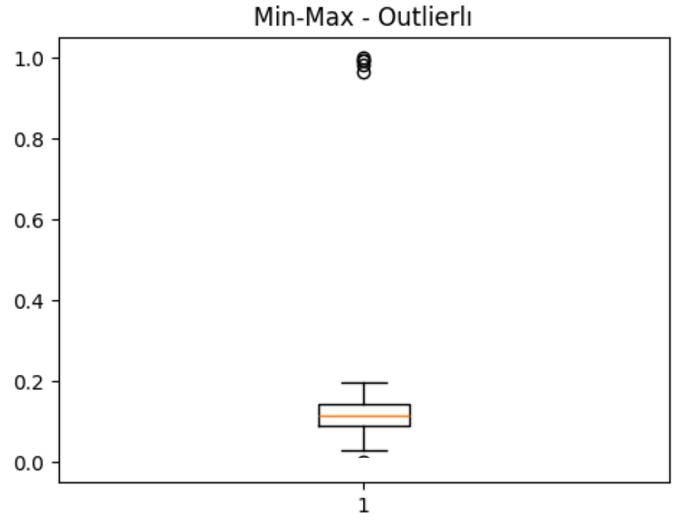
Bu derste normalization = MinMax; standardization = mean/std.
MaxAbs ve Robust diğer scaling seçenekleridir; uygulama yok.

Scaling Nasıl görünüyor

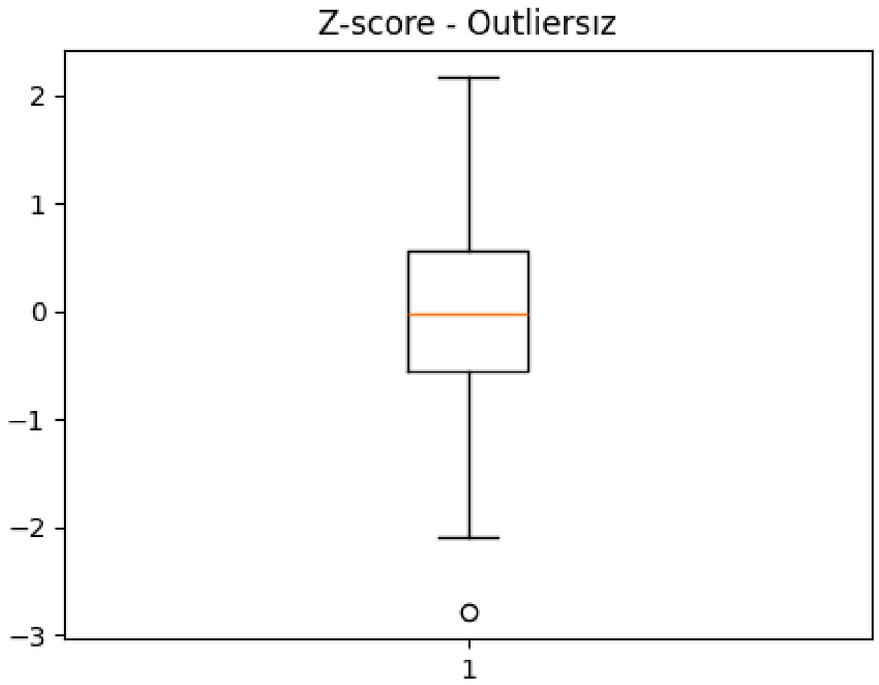


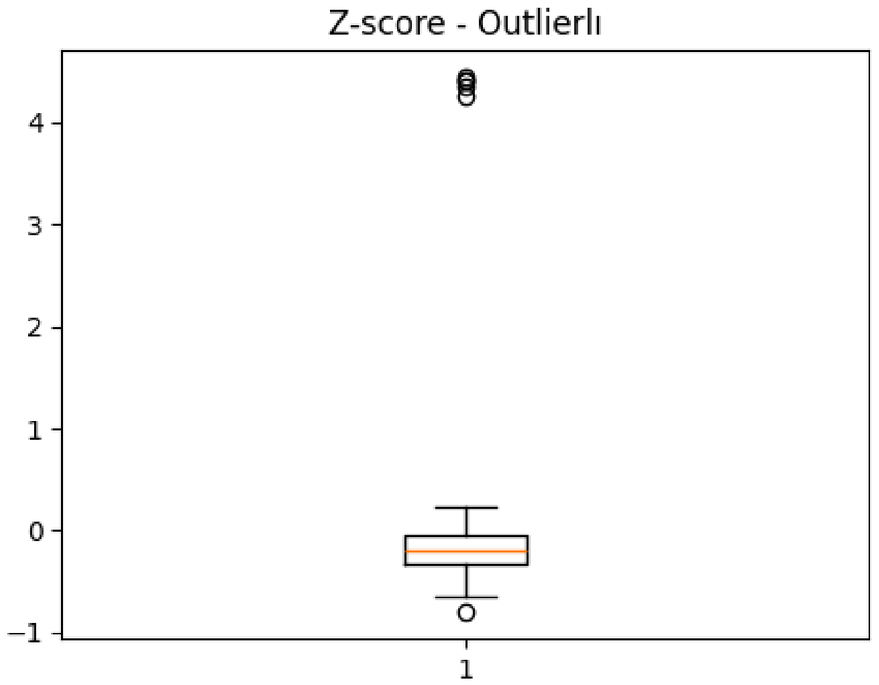






Scaling Nasıl görünüyor





Min-Max Scaling

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Train değerlerini 0–1 aralığına taşır.
Yeni değerler bu aralığın dışına çıkabilir.
Outlier'lara duyarlıdır.

Before Scaling	After Scaling
0	0
20	0.2
40	0.4
60	0.6
80	0.8
100	1.0

$X_{max} - X_{min} = 100-0 = 100$

For 0

(0-0)/100 = 0

For 60

(60-0)/100 = 0.6

For 100

(100-0)/100 = 1.0

Z-score Scaling

$$z = \frac{x - \mu}{\sigma}$$

x : data
μ : mean
σ : standart deviation

Standardization: train mean=0, std=1.

Outlier'lardan etkilenir.

Normal dağılım yaratmaz; normal dağılım şart değildir.

40	-1.35
50	-0.45
60	0.45
70	1.35

std = 11.1 **std = 1**

mean = 55 **mean = 0**

Encoding

- AI/ML algoritmaları sayısal değerler ile çalışır. Sayısal olmayan değerlerin sayısal değerlere çevrilme çabası vardır.
- Categorical verilerin sayısal değerlere çevrilmesi işlemine “encoding” denir.
- Encoding işleminin feature’lara uygun yapılması önemlidir. Bu yüzden feature sütunları bu işlemden önce incelenmeli bilgi sahibi olunmalıdır.

Unique Value: Bir sütun içerisindeki her bir eşsiz değere denir. Bir sütunda kaç tane unique value olduğu hem veri analizi için hem de encoding işlemi için önemlidir.

- Unique value ile uğraşırken izlenebilecek en iyi yöntem veri setini detaylıca inceleyip her bir unique değerin anlamını bilmektir. Ancak her zaman mümkün değil.

Ankara
İstanbul
İzmir
Ankara

Unique Value = 3

Kırmızı
Yeşil
Mor
Mavi

Unique Value = 4

positive
negative
positive
positive

Unique Value = 2

positive
negative
positie
positive

Unique Value = 3

Yazım hatası gibi durumlar yeni bir unique value gibi görünebilir. Encoding işlemine geçmeden önce bu yanlışlıkların düzeltilmesi iyidir.

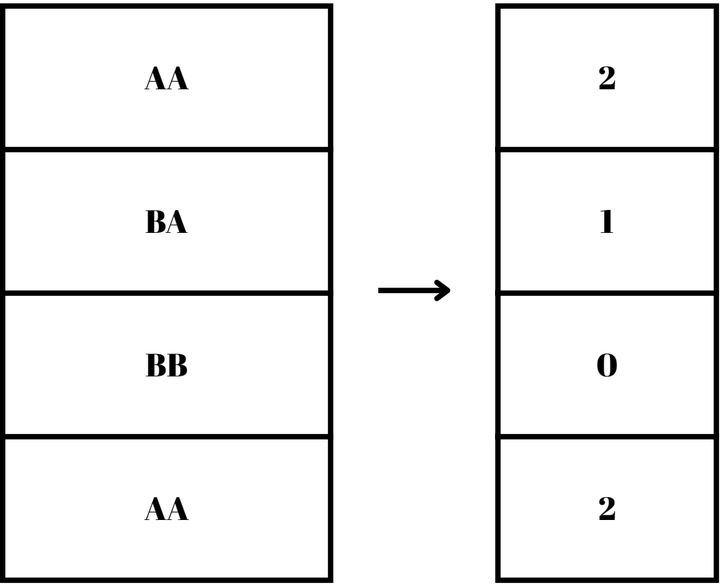
Label Encoding

Red	0
Green	1
Red	0
Blue	2



- Kategoriye sayı atama, yapay bir sıralama yaratabilir.
- Notebookta LotConfig örneği bu riski gösterir.
- Sklearn LabelEncoder hedef y içindir; nominal girdide one-hot tercih edilir.

Ordinal Encoding



- Anlamlı sıra varsa sayısal kod kullanılır: BB < BA < AA.
- Bu dönem kısa tanım; ayrı uygulama yok.

Frequency Encoding

Red	→	2	or	0.4
Green		2		0.4
Green		2		0.4
Blue		1		0.2
Red		2		0.4

- Kategori, görülme sayısı / oranıyla temsil edilir.
- Farklı kategoriler aynı sıklığı alabilir.
- Bu dönem kısa tanım; ayrı uygulama yok.

One-Hot Encoding

Red
Green
Green
Blue
Red



is_red	is_green	is_blue
1	0	0
0	1	0
0	1	0
0	0	1
1	0	0

- Her bir unique value için yeni bir sütun oluşturulur. Bu sütunda unique değere karşılık gelen satırlara 1 geri kalanlara 0 yazılır.
- Her bir unique value için algoritmanın öğrenmesi sağlanır.
- Çok fazla unique value varsa bu işlem maliyetli olur.

Feature Selection

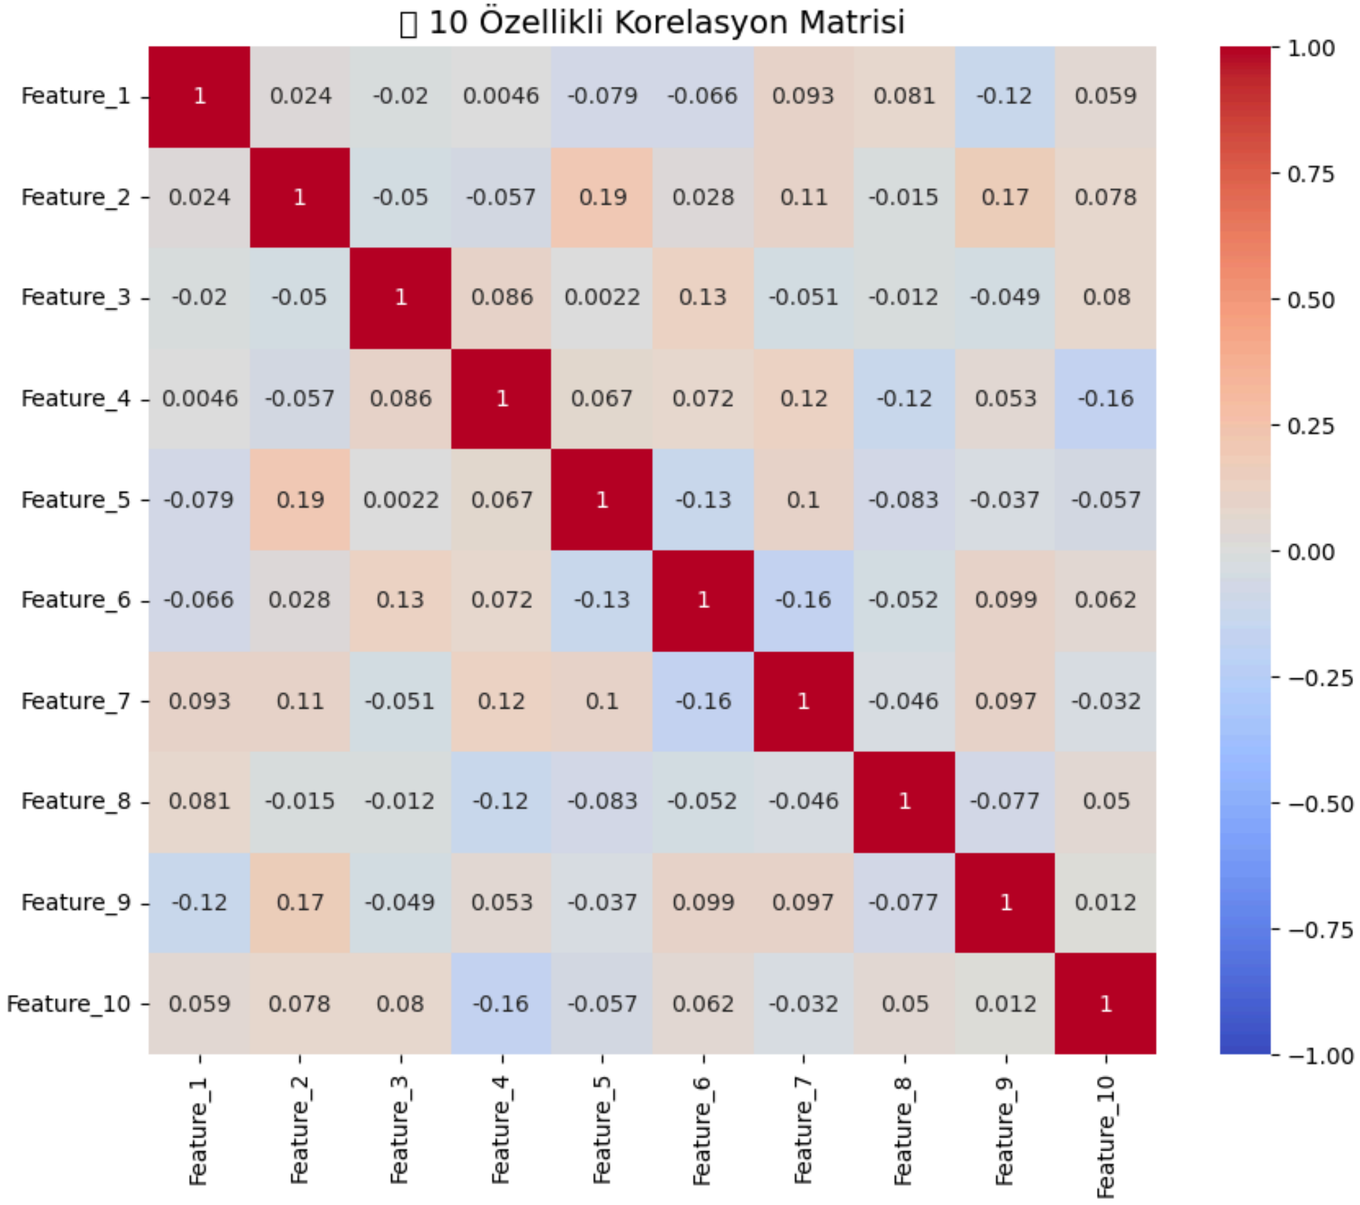
Anlamlı özellikleri seçmek, modeli daha kolay yorumlamayı sağlar.

Bu dönem seçili sütunların korelasyonunu inceliyoruz.

Mutual Information: doğrusal olmayan ilişkiyi de ölçen alternatif; uygulama yok.

Seçim yalnızca eğitim verisinden öğrenilmelidir.

Correlation Matrix



Pearson korelasyonu doğrusal ilişkiyi ölçer.
−1: güçlü negatif; +1: güçlü pozitif.
0: doğrusal ilişki yok; başka ilişki olabilir.

Korelasyon nedensellik veya tek başına özellik önemi değildir.
Ödev 3: Age/VIP eksiklerini doldur, PassengerId'yi çıkar. Temiz tabloda kalan metin sütunları ayrıca encoding gerektirebilir.